Desarrollo de un MVP de Mantenimiento Predictivo IoT con Machine Learning

Este proyecto consiste en el desarrollo de un Producto Mínimo Viable (MVP) de mantenimiento predictivo impulsado por Machine Learning, utilizando específicamente un algoritmo de aprendizaje no supervisado: Isolation Forest. El objetivo de este algoritmo es aprender el perfil de vibraciones de una máquina operando en su estado "normal", es decir, su Línea Base. Cualquier desviación o evento fuera de esta burbuja geométrica de normalidad es clasificado como una anomalía.

A nivel de negocio, esta capacidad de detectar daños incipientes permite intervenir en la maquinaria antes de que se produzca una falla catastrófica. Los beneficios directos incluyen: la eliminación de paradas imprevistas de producción (lucro cesante), la reducción drástica de costes por reparaciones mayores, y la protección de la reputación frente a clientes al garantizar la continuidad del servicio.

Este enfoque supone un salto cualitativo frente a las estrategias de mantenimiento industrial tradicionales:

- **Mantenimiento Correctivo:** Consiste en reparar el activo una vez que se ha producido la rotura, lo que conlleva paradas imprevistas y riesgo de daños secundarios graves.
- **Mantenimiento Preventivo:** Se basa en revisiones por calendario o sustitución de piezas por horas de uso. Incurre en altos costes fijos y sustitución de componentes que aún poseen vida útil.
- **Mantenimiento Predictivo:** Permite intervenir únicamente cuando el algoritmo detecta una degradación real. Maximiza el ciclo de vida del componente y elimina las revisiones innecesarias.

Validación teórica previa con el dataset de CWRU

Antes de la fase física, el modelo de ML se validó utilizando el dataset industrial de vibraciones de la Case Western Reserve University (CWRU). El algoritmo alcanzó un 91% de precisión global, y al analizar su matriz de confusión se obtuvo: un 0% de falsas alarmas y un 91% de precisión para detectar fallos.

Arquitectura del MVP y Validación Física

Para validar esta arquitectura en un entorno físico, se construyó un banco de pruebas utilizando un motor rotativo de velocidad constante (un ventilador doméstico). La infraestructura se divide en las siguientes capas:

1. **Captura y Edge Computing:** Las vibraciones se monitorizan mediante un acelerómetro MEMS (MPU-6050) conectado por bus I2C a una Raspberry Pi. Este

microordenador realiza el procesamiento de señales en el Edge (borde), calculando variables estadísticas significativas en el dominio del tiempo (RMS, Factor de Cresta, Curtosis) y aplicando la Transformada Rápida de Fourier (FFT) para analizar el espectro de frecuencias.

2. **Almacenamiento y Visualización:** Las series temporales se almacenan de forma local en InfluxDB. Para la monitorización, se diseñó un panel de control en Grafana, accesible vía Wi-Fi desde cualquier equipo, que permite observar la señal cruda y la evolución de los parámetros característicos en tiempo real.

3. **Inferencia y Sistema de Alertas:** El modelo Isolation Forest se despliega en la Raspberry Pi. Para dotar al sistema de robustez y evitar "falsos positivos" ante ruidos aislados, se implementó una ventana deslizante temporal. Si el algoritmo detecta una persistencia de la anomalía durante varias ventanas de evaluación consecutivas, dispara un evento automatizado a través de la API de Telegram, enviando una alerta crítica al dispositivo móvil del equipo de mantenimiento.

Validación Física y Resolución de Problemas

Para validar esta arquitectura en un entorno físico, induje desequilibrios mecánicos mediante la fricción controlada de distintos objetos contra las aspas del ventilador en funcionamiento. Adjuntos a este post, se encuentran los resultados de las pruebas que aquí resumo. Realicé 4 pruebas, y aunque el modelo inicial ya presentaba una precisión global (Accuracy) muy alta (entre el 90% y el 98%), esta métrica era engañosa al estar inflada por la enorme cantidad de aciertos en estado sano. El verdadero reto estaba en el porcentaje de captación de anomalías (Recall). En la primera prueba, el sistema sólo detectó el 23% de los fallos reales. Tras implementar una lógica de ventanas de tiempo y persistencia del error, logré elevar esa captación hasta un 100% de eficacia, eliminando además las falsas alarmas.

Escalabilidad y Presupuesto

La metodología empleada sirve para proteger distintos activos. Puede extrapolarse para monitorizar compresores, bombas centrífugas u hornos, ajustando únicamente los sensores (temperatura, ultrasonidos, corriente). El coste de hardware del prototipo demuestra la viabilidad de democratizar esta tecnología:

- Microordenador (Raspberry Pi 2)*: ~30€
- Acelerómetro triaxial (MPU-6050): ~2€
- Cable Jumper: ~0.50€

** Nota: Esta arquitectura es compatible con microcontroladores de coste inferior a 5€, como el ESP32. A la hora de escalar a nivel industrial, esta es una mejor opción.*

Futuras mejoras

- **Motor Current Signature Analysis (MCSA):** En la industria, perforar o intervenir la carcasa de una máquina anula la garantía del fabricante. Un método no invasivo consiste en analizar la corriente eléctrica directamente desde el cuadro eléctrico mediante pinzas amperimétricas. Con este método, es posible detectar bandas laterales de frecuencia anómalas que indican desgaste mecánico sin necesidad de intervenir la máquina.

- **Order Tracking para velocidad variable:** A diferencia del ventilador de pruebas, la maquinaria industrial modifica su régimen de giro. Para evitar que el Machine Learning confunda una aceleración por exigencias de producción con un fallo catastrófico, se implementarán variables adimensionales. El eje de frecuencias pasará a medirse en "Órdenes" (múltiplos de la velocidad principal o 1X), y la amplitud de vibración se normalizará dividiéndola entre el cuadrado de la velocidad de giro, ya que la fuerza centrífuga generada por una masa desequilibrada en un rotor es proporcional al cuadrado de su velocidad angular: $F = m \cdot r \cdot \omega^2$.

- **Gestión del Envejecimiento (Concept Drift):** Las máquinas sufren un desgaste natural que altera su vibración base con el tiempo. La arquitectura del modelo real deberá contemplar una rutina de reentrenamiento automático periódico para desplazar la "burbuja de normalidad" y mantener la precisión del sistema a largo plazo.

Imágenes

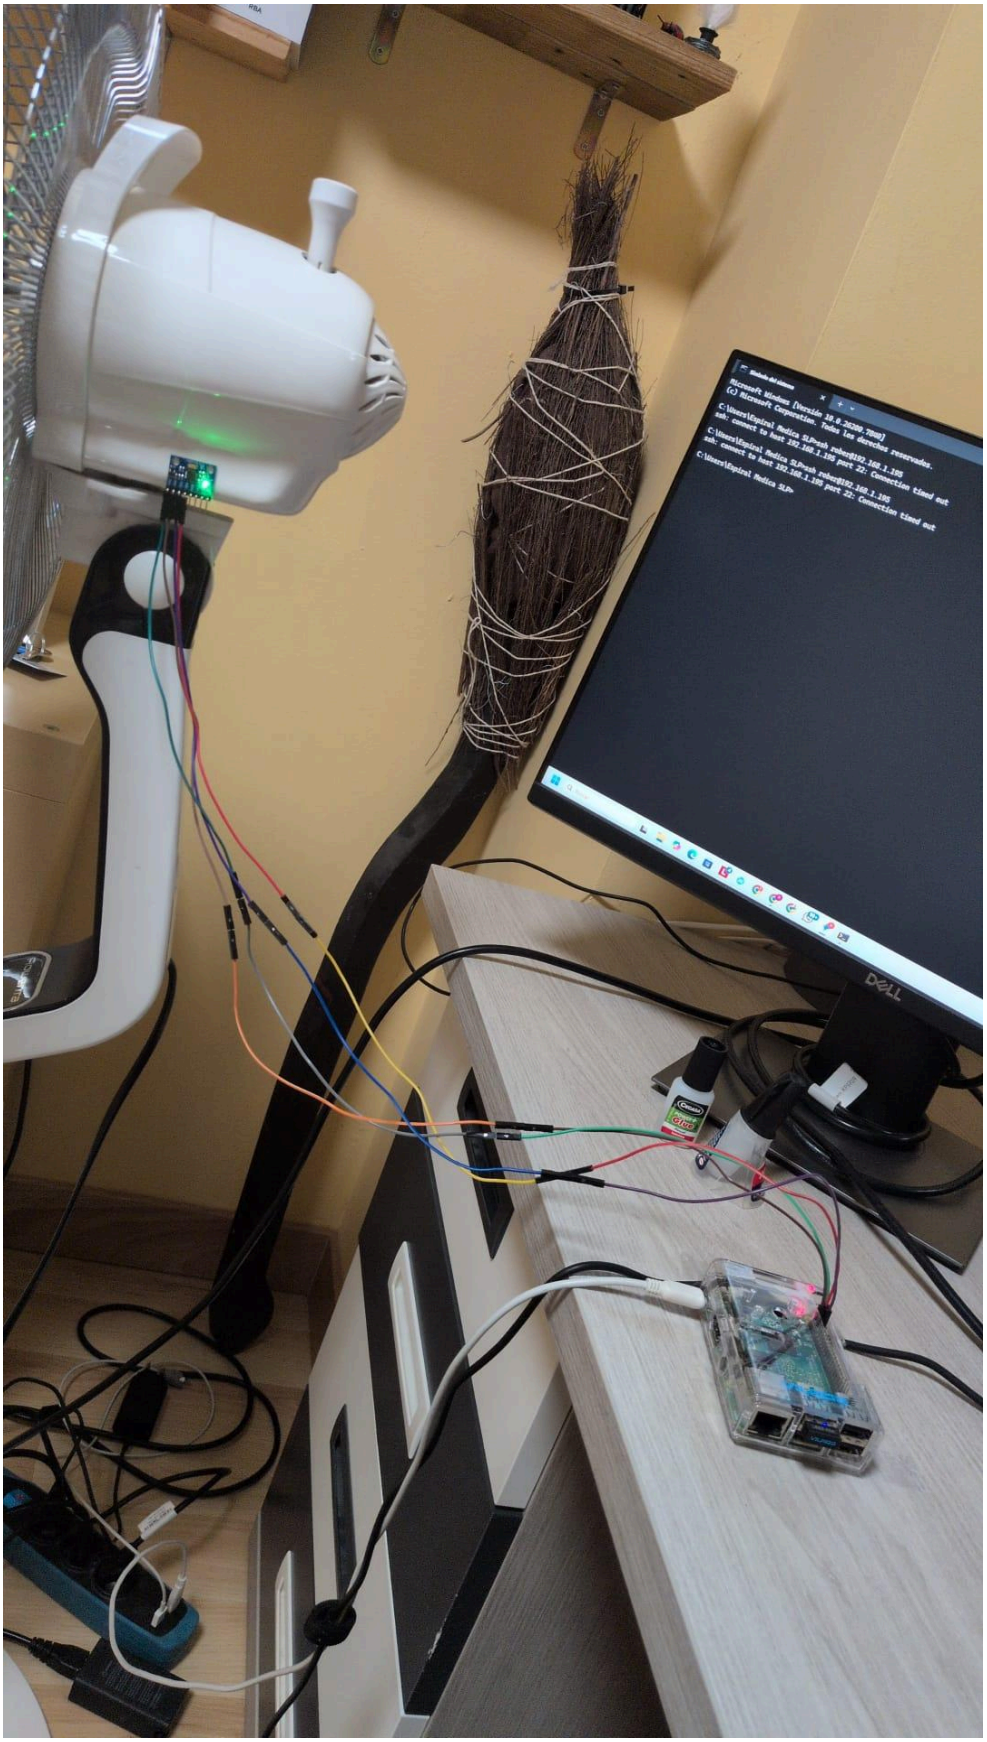
Microsoft Windows [Versión 10.0.26200.7840]
(c) Microsoft Corporation. Todos los derechos reservados.
C:\Users\Ingenial Medica SLP>ssh robot@192.168.1.195
ssh: connect to host 192.168.1.195 port 22: Connection timed out
C:\Users\Ingenial Medica SLP>ssh robot@192.168.1.195
ssh: connect to host 192.168.1.195 port 22: Connection timed out
C:\Users\Ingenial Medica SLP>
DELL

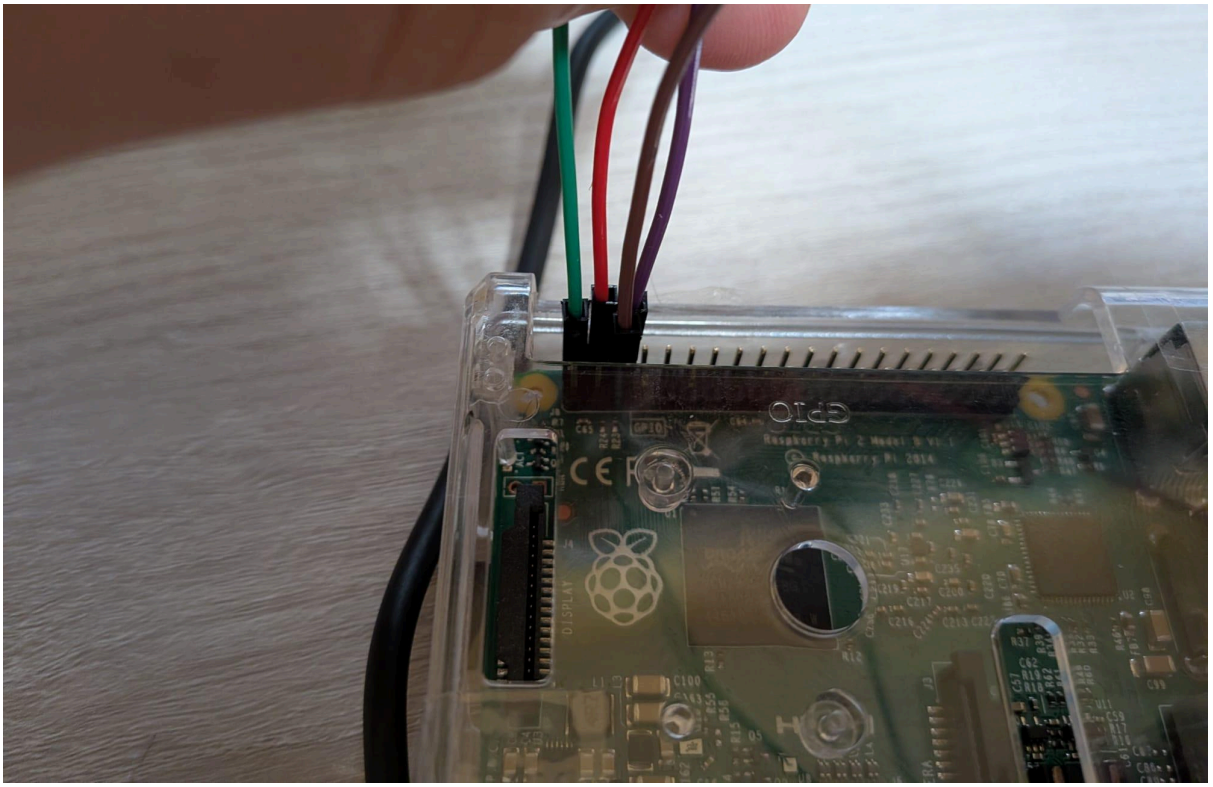
GPIO
DISPLAY

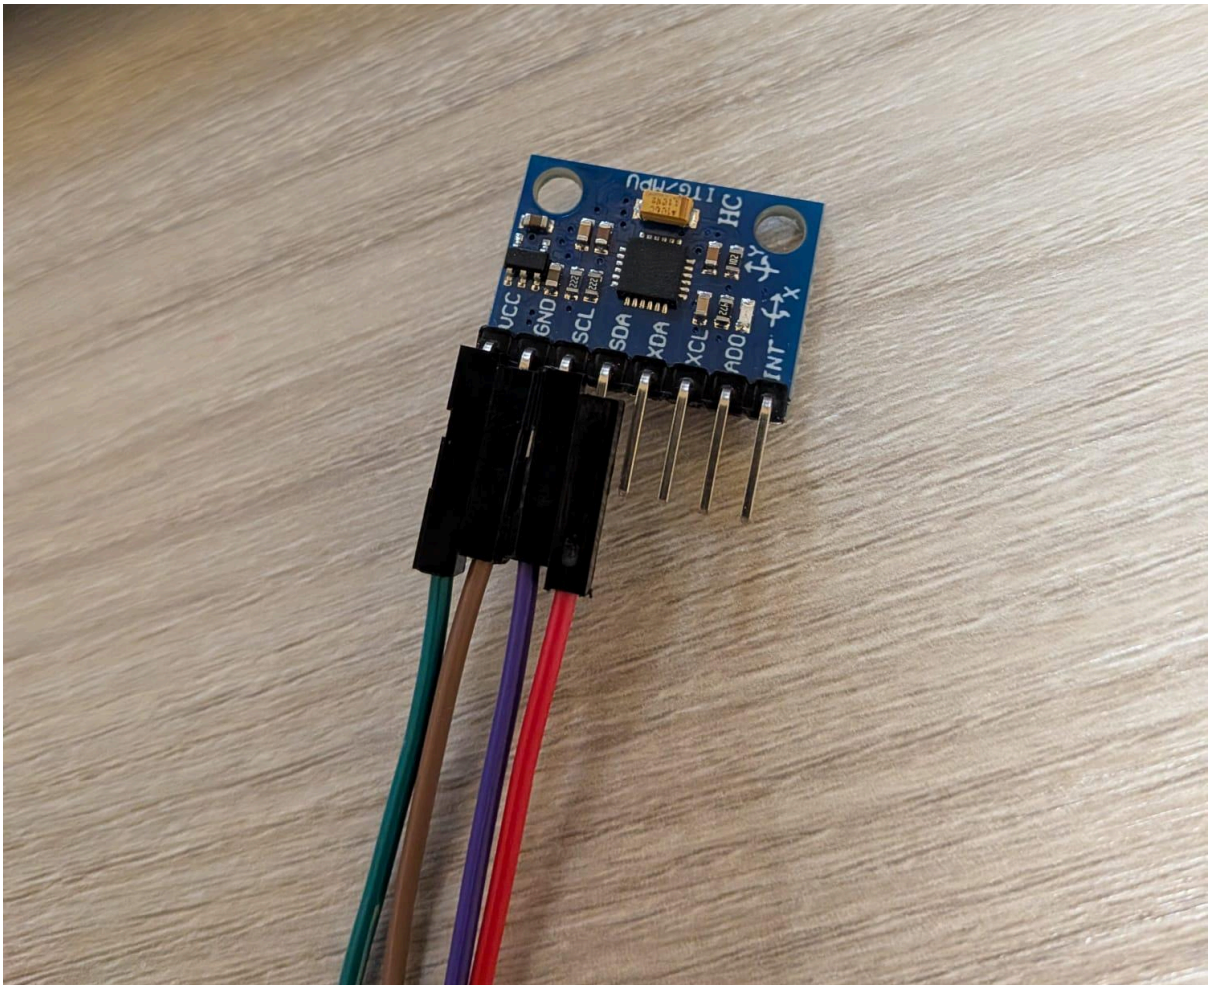
HC
VCC
GND
SCL
SDA
XDA
XCL
ADO
INT

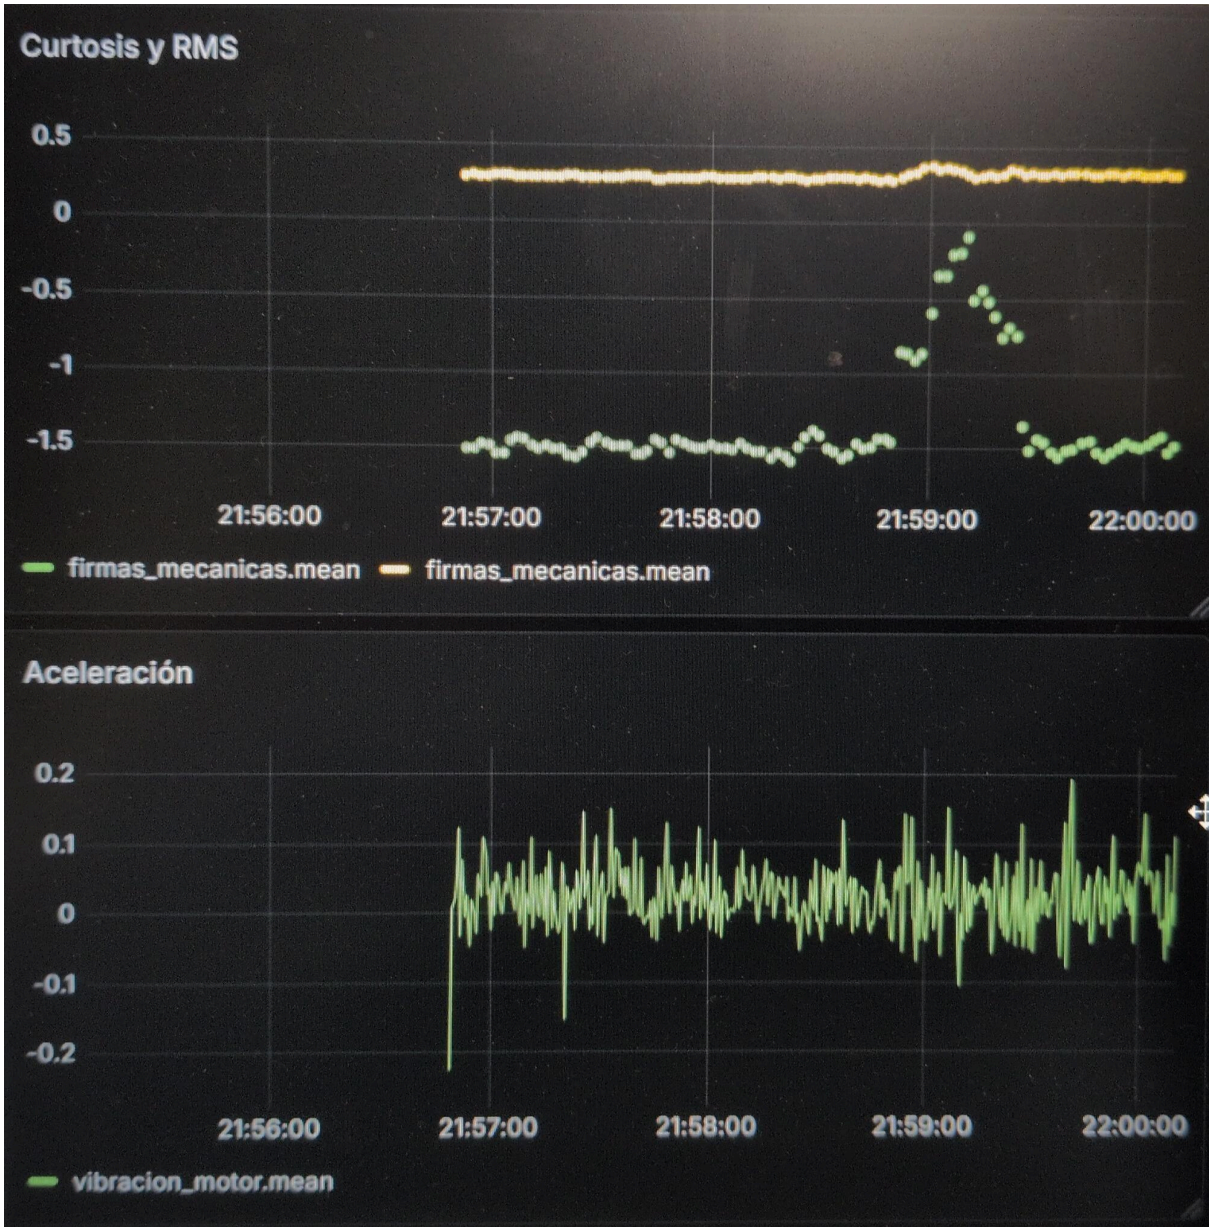
Curtosis y RMS
0.5
0
-0.5
-1
-1.5
21:56:00
21:57:00
21:58:00
21:59:00
22:00:00
firmas_mecanicas.mean
firmas_mecanicas.mean
Aceleración
0.2
0.1
0
-0.1
-0.2
21:56:00
21:57:00
21:58:00
21:59:00
22:00:00
vibracion_motor.mean

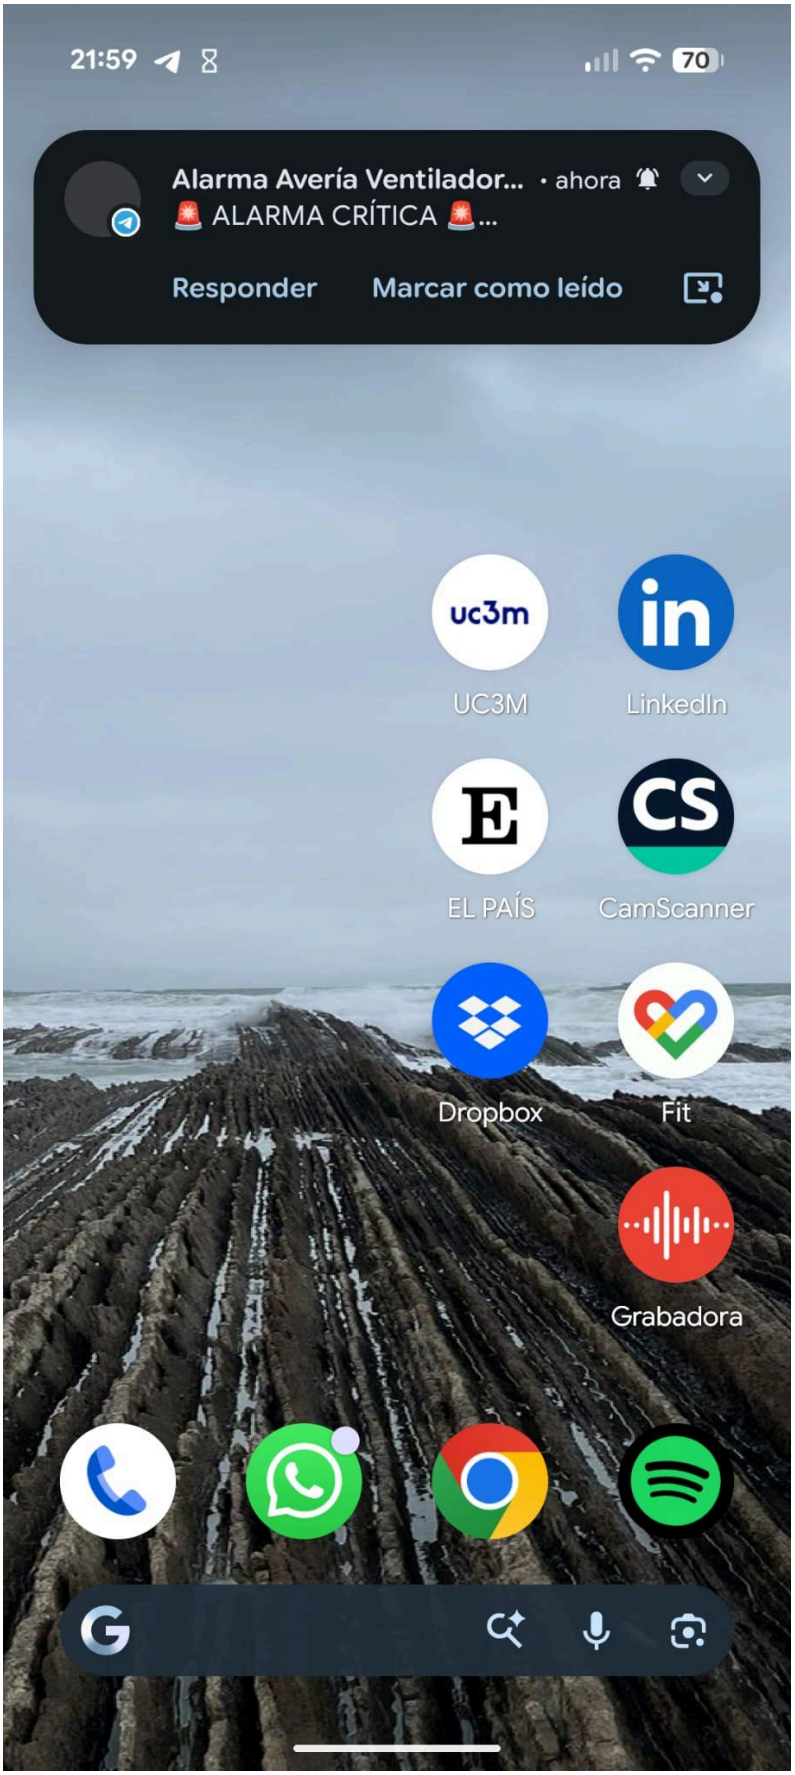
21:59
70
Alarma Avería Ventilador... • ahora
🚨 ALARMA CRÍTICA 🚨...
Responder
Marcar como leído
UC3M
LinkedIn
EL PAÍS
CamScanner
Dropbox
Fit
Grabadora